




AIMovieMind (AIM)

Machine Learning


Artificial Intelligence

Trasformers

План лекции



- 01 А что, если...
- 02 Это не баг, а фича
- 03 Хьюстон, у нас проблемы!
- 04 Миссия выполнена
- 05 Перспективы



А что, если...



01

Зарождение идеи

Я выучила английский до среднего уровня, стоит внедрять его в свою жизнь: фильмы, youtube - все на английском. Но точно ли я правильно понимаю спикеров..?

02

Поиск готового решения

Вспомнила о существовании разборов разных фильмов на youtube. Они полезные, но мне этого мало. Я смотрю сериал office, для него таких разборов нет, как быть...

03

Необходимость для пользователей

Учителя английского точно знают, если ли готовые решения на рынке. Нет.? Делаю опрос среди них, нужно ли решение, и в каком формате.

04

Формирование цели

Придется самой создать такой сервис. Беру идею учебника Keynote, который был создан на основе подкастов TED Talks. Решаюсь создать похожее, только в онлайн.

05

Выбор инструментов

Мое направление - искусственный интеллект, поэтому его точно стоит использовать. Чтобы этим смогли пользоваться другие люди, потребуется создать сайт.

06

Реализация

Начинаю поиски моделей. Есть ощущение, что брать готовые LLM опасно, так как большой объем данных может спровоцировать галлюцинации. Надо подумать...



AIMovieMind - сайт для генерации вопросов по транскрипции фильма/сериала/подкаста

Оно помогает пользователям лучше понимать и анализировать информацию, предлагая вопросы для проверки владения материалом после его изучения.

Цель проекта:

- Улучшить самообразование по английскому языку
- Помочь внедрить пользователям иностранный язык в повседневность

Это не баг, а фича!



01

Чанки

Текст по абзацам разбивается на чанки.
Каждый фильтруется и векторизуется для того, чтобы передать модели.

02



Кластеры

Эмбединги чанков кластеризуются на количество_чанков * 0.01 кластеров.
Из каждого кластера берётся ближайший к центру кластера объект.


03

LLM

Центральные объекты каждого кластера передаются на вход LLM




Хьюстон, у нас проблемы!




Отсутствие данных

Изначально была идея дообучить существующую нейронку. Были проведены эксперименты с языковой моделью BERT, но основная загвоздка в обучении - очень маленький объем данных



Попытка исправить ситуацию

Я решила попробовать написать свой собственный парсер для того, чтобы собрать данные с проверенных сайтов. Так как я делала это впервые, мне удалось собрать около 50 текстов, что мало для дообучения



Решение

Чтобы добиться хорошего качества на первых этапах, я решила взять DeepSeek как основной вариант. При этом итоговый код написан так, чтобы в любое время можно вставить собственную модель


ooo

```
from generation import QuestionsGenerator

with open('text.txt', 'r', encoding='utf8') as f:
    text = f.read()


# Генерация 10 вопросов по тексту
generator = QuestionsGenerator()
questions = generator.generate(text, 10)
```

Миссия выполнена



Сайт

Для меня самым удобным и лучшим вариантом стала библиотека Streamlit на Python. Она позволила сделать проект доступным для пользователей.



Возможности


На данный момент сайт обладает неполноценным, но достаточным функционалом для работы. В первую очередь, можно выбрать количество вопросов, которые выдаст модель для вашего текста. Именно это просили реализовать учителя в первую очередь.



AIMovieMind: Генерация заданий по транскриптам


Вставьте транскрипт фильма, подкаста или сериала:

Сколько вопросов сгенерировать?




 Сгенерировать вопросы

Перспективы



Собственная модель


Создав свою базу данных, я смогу более точно отвечать на запросы пользователя, ведь собственная модель будет уметь не просто анализировать текст, но и искать полезную информацию, которая также необходима для улучшения навыков английского языка



Умный поиск

Понимание текста основывается на понимании отдельных фраз, поэтому в следующей версии будет добавлено:


- Поиск устойчивых выражений
- Объяснение жаргонов и сленга
- Анализ шуток для понимания культурных особенностей



Аккаунт


Каждому пользователю будет представлена возможность создания собственного аккаунта. В нем можно будет:

- Сохранить ранее введенные транскрипции
- Создать свою библиотеку любимых фраз, жаргонов, сленговых выражений



Библиотека

Чтобы упростить пользователю поиск транскрипции в интернете, будет создана своя библиотека фильмов/сериалов/подкастов. Можно будет с легкостью обратиться к модели и получить задания, или же самому прочитать субтитры к любимому фильму



**Хотите изучить код?
Проверить все на
практике?
Приглашаю вас в
свой GitHub!**



Спасибо
за внимание

